

Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Guadalajara

Modelación del aprendizaje con inteligencia artificial
Gpo 301

Reporte individual: Análisis de datos de actividad cerebral

Profesor: Omar Mendoza Montoya

Mayra Sarahí De Luna Castillo A01635774

Reporte individual: Análisis de datos de actividad cerebral


Este proyecto tomó como base un par de experimentos neuropsicólogos para adquirir datos cerebrales e implementar modelos de clasificación. Se dividió en cuatro principales etapas: recolección de datos, preparación de los datos, evaluación de modelos de clasificación y transferencia del aprendizaje, mismos que se encuentran en el código en Python. A continuación se explicarán los pasos que se llevaron a cabo para llegar a una solución.

→ Descripción del proyecto

Para poder comenzar con este proyecto, primero se debe tener una clara definición de lo que es electroencefalografía. Se trata de un estudio que mide la actividad eléctrica del cerebro (comunicación de neuronas a través de impulsos eléctricos) con electrodos que se colocan sobre el cuero cabelludo y referencias (terminales negativas), que para este experimento se colocaron debajo de los lóbulos de las orejas.

Las señales EEG se interpretan como una composición de oscilaciones rítmicas, llamadas ritmos cerebrales que son la sumatoria de senos y cosenos a diferente frecuencia, la frecuencia aumenta mientras se realizan tareas cognitivas de alto nivel. Esto nos ayudará a desarrollar los dos experimentos que se presentan en este proyecto.

El equipo con el que se trabajó fue “*Unicorn Hybrid Black*”, un dispositivo EEG portátil de 8 canales de alta calidad para la interfaz cerebro-computadora comercializado por gTec. Los 8 canales representan una distinta posición en la cabeza y van del 1-8 empezando por el frente de la cabeza y bajando de izquierda a derecha, se nombran con las siguientes siglas: Fz, C3, Cz, C4, Pz, PO7, Oz, PO8

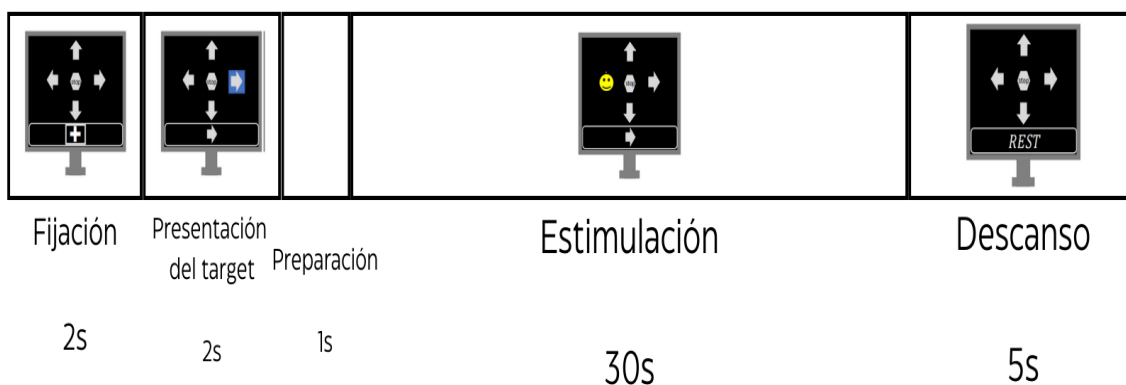


Estos canales cumplen con el posicionamiento internacional 10-20 que hace referencia al porcentaje de distancia en la que deben estar colocados los electrodos en la parte frontal,

occipital, lado derecho e izquierda del cráneo. Este equipo tiene una velocidad de muestreo de 250 mediciones por segundo o 250 Hz, el valor típico en los que las oscilaciones deben estar es entre los 100 Hz-500 Hz por segundo debido a que en cuero cabelludo no se puede percibir actividad de mayor frecuencia y el rango debe estar entre -100 μV a 100 μV , arriba o abajo de ese rango se considera que las frecuencias tienen mucho ruido.




Se realizaron dos experimentos para la parte de recolección de datos y preparación de los mismos:

- **P300:** Se muestra una interfaz en donde se ubican con una flecha los puntos cardinales y en el medio un botón, el experimento viene de la aparición de una carita feliz en alguno de los puntos disponibles, el usuario debe observar y contar las veces que aparece la carita feliz en el lugar mostrado al usuario por el programa. Las características de este programa se extraen durante los 800 milisegundos posterior a la aparición de la carita feliz, luego se le agrega un filtro pasabanda que elimina las mediciones abajo de los 4 Hz y arriba de los 20 Hz, luego se hace un submuestreo donde se descartan observaciones de manera periódica para comprimir los datos (submuestreo entre 4) y finalmente pasa por la técnica de filtrado espacial el cual combina las señales para obtener nuevas que tengan mejores propiedades que las anteriores.



- **Tarea cognitiva:** Se muestra una interfaz en donde se le pide al usuario realizar distintas tareas cognitivas (cálculo, lectura y nombres de cosas) y entre cada una de ellas se muestra una cruz y posterior hay un descanso. La realización de las tareas tiene una duración de 15 segundos y se dividen en 15 ventanas de 1 segundo para la extracción de las observaciones, por otro lado la aparición de la cruz tiene una duración de 10 segundos y se dividen en 10 ventanas de un segundo para la extracción, el tiempo de descanso se elimina. En este caso se hace uso de un análisis de potencia espectral (psd) en donde se obtiene una gráfica en el eje

horizontal de frecuencia y en el eje vertical de energía, a mayor amplitud de oscilación, mayor energía. Lo anterior es lo que se busca cuando el usuario este realizando tareas cognitivas

		
Cruz	Tarea cognitiva	Descanso
10s	15s	5s

Las tareas cognitivas, como se mencionó anteriormente se dividió en tres apartados, las indicaciones que se dió en cada una fueron:

Cálculo	Lectura	Nombre de cosas
<p>Resuelve mentalmente</p> $\begin{array}{ll} 22 - 15 = ? & 17 - 17 = ? \\ 21 - 18 = ? & 33 - 13 = ? \\ 27 - 13 = ? & 14 - 5 = ? \\ 25 - 5 = ? & 20 - 15 = ? \\ 20 - 16 = ? & 18 - 14 = ? \end{array}$	<p>Lee en silencio el siguiente texto:</p> <p>De acuerdo a varios historiadores, la tarta de queso es el postre más antiguo que se conoce. Se remonta a varios siglos atrás, cuando los antiguos griegos la preparaban con harina, miel y queso. Se cree que la tarta de queso se sirvió por primera vez en los Juegos Olímpicos de 776 a.C. como alimento para los atletas. Más tarde, los romanos adoptaron la receta y la difundieron por Europa. Con el paso del tiempo, la tarta de queso fue evolucionando y adquiriendo diferentes formas y sabores según los ingredientes locales de cada región. Hoy en día, existen muchas variedades de tarta de queso, desde la clásica de Nueva York hasta la japonesa de algodón.</p>	<p>Imagina nombres de comidas típicas de México que puedes comprar en la calle</p>
<p>Resuelve mentalmente</p> $\begin{array}{ll} 21 \div 3 = ? & 54 \div 6 = ? \\ 45 \div 5 = ? & 48 \div 2 = ? \\ 39 \div 3 = ? & 55 \div 5 = ? \\ 77 \div 7 = ? & 42 \div 7 = ? \\ 36 \div 2 = ? & 48 \div 4 = ? \end{array}$	<p>Lee en silencio el siguiente texto:</p> <p>Para muchos tecnólogos, la primera computadora la diseñó y construyó el ingeniero alemán Konrad Zuse entre 1935 y 1936. Dicha computadora se conoce como la Z1, la cual era una máquina mecánica programable capaz de usar el sistema binario y realizar cuatro operaciones matemáticas básicas. La Z1 fue destruida durante un bombardeo en Berlín en 1943, pero Zuse construyó otros modelos más avanzados como la Z2 y la Z3, que usaban relés electrónicos. La Z3 está considerada como la primera computadora electromecánica y la primera en usar el lenguaje de programación Plankalkül, también creado por Zuse.</p>	<p>Imagina nombres de instrumentos musicales</p>
<p>Resuelve mentalmente</p> $\begin{array}{ll} 13 \times 5 = ? & 11 \times 9 = ? \\ 70 \times 9 = ? & 16 \times 5 = ? \\ 45 \times 3 = ? & 19 \times 1 = ? \\ 56 \times 2 = ? & 30 \times 3 = ? \\ 22 \times 8 = ? & 27 \times 2 = ? \end{array}$	<p>Lee en silencio el siguiente texto:</p> <p>¿Sabías que en 1936 una mujer estadounidense llamada Isabella Gilbert inventó un aparato que prometía crear hoyuelos en las mejillas? Se trataba de un dispositivo que se colocaba sobre la cara y ejercía presión sobre los pómulos con unos resortes metálicos. Según las instrucciones, había que usarlo cinco minutos, dos o tres veces al día. Sin embargo, la Asociación Médica de Estados Unidos denunció el invento, asegurando que no solo no creaba hoyuelos, sino que su uso prolongado podía llegar a generar cáncer. No parece una buena idea, ¿verdad?</p>	<p>Imagina nombres de personas que comiencen con la letra M</p>
<p>Resuelve mentalmente</p> $\begin{array}{ll} 32 + 15 = ? & 17 + 17 = ? \\ 18 + 21 = ? & 29 + 3 = ? \\ 27 + 13 = ? & 13 + 14 = ? \\ 15 + 25 = ? & 20 + 15 = ? \\ 36 + 6 = ? & 8 + 14 = ? \end{array}$	<p>Lee en silencio el siguiente texto:</p> <p>El rayo de la muerte de Tesla era un arma teórica que permitía disparar un haz de partículas microscópicas hacia seres vivos u objetos para destruirlos. Supuestamente fue inventado entre la década de 1920 y 1930 por Nikola Tesla, un científico e inventor serbio que emigró a los Estados Unidos. Tesla decía haber inventado un rayo de la muerte usando lo que él denominaba "teleforce", una forma de transmitir energía eléctrica sin cables. El aparato nunca fue desarrollado ni demostrado públicamente, pero ha alimentado la imaginación de muchos autores de ciencia ficción y ha inspirado la creación de conceptos como la pistola de rayos láser.</p>	<p>Imagina nombres de animales mamíferos</p>

→ Resultados obtenidos

Descripción de los clasificadores

Para la evaluación de los algoritmos con los datos obtenidos por los 2 experimentos mencionados anteriormente se trabajaron 3 distintos casos:

- Clasificación de potencial P300 vs no potencial P300.
- Clasificación de no tarea cognitiva (cruz) vs tarea cognitiva
- Clasificación de tarea de cálculo (9-12) vs tarea de lectura (5-8) vs tarea de nombres de cosas (1-4).

Cada caso pasó por 5 clasificadores para observar su rendimiento (SVM, KNN, MLP, Random Forest, Decision Tree), a continuación se presenta una breve explicación de cada uno.

SVM: Este clasificador busca encontrar un hiperplano óptimo para separar los datos en diferentes clases, maximiza el margen entre las clases y utiliza vectores de soporte. El clasificador se rige por dos principales hiperparámetros:

- C: Controla el balance entre la clasificación correcta y la maximización del margen
- Kernel: Define la función de transformación que se utiliza para mapear los datos, puede ser lineal, polinómico y radial basis function (RBF).

KNN (K-Nearest Neighbors): Clasifica un conjunto de datos desconocidos asignándole la etiqueta de clase más común entre sus vecinos más cercanos. Los vecinos se seleccionan según una medida de distancia (generalmente euclidiana). Para este proyecto se usaron 8 vecinos. Este clasificador se rige por el siguiente hiperparámetro:

- K: Especifica el número de vecinos más cercanos que se consideran al realizar una clasificación.

MLP (Multilayer Perceptron): Es una red neuronal artificial que consta de multicapas de unidades llamadas neuronas, estas se organizan en capas de entradas, ocultas y de salida, utilizan una función de activación para introducir no linealidad, este clasificador aprende a través de retropropagación de error y ajusta los pesos de las conexiones para mejorar la

precisión del clasificador. Para este proyecto se usaron 3 capas. Los hiperparámetros por los que se rige son:

- Número y tamaño de las capas ocultas: Especifica el número de capas ocultas y el número de neuronas en cada capa oculta. Más capas significa un aumento en la capacidad del modelo, pero también puede conducir a un sobreajuste.
- Función de activación: Define la función que se aplica a la salida de la cada neurona (sigmoide, ReLU y tangente hiperbólica).

Árbol de decisión: Este clasificador divide repetidamente un conjunto de datos en subconjuntos más pequeños utilizando características relevantes. Los hiperparámetros por los que se rigen son:

- Criterio de división: Criterios para medir la calidad de la división de datos.
- Profundidad máxima del árbol: Controla la cantidad máxima de niveles del árbol.

Random Forest: Este clasificador se explicará con más detalle a lo largo del texto, pero en resumen es un conjunto de árboles de decisión en el que cada uno se entrena con una muestra aleatoria de un conjunto de datos. Los hiperparametros por los que se rigen son:

- Número de árboles: Especifica la cantidad de árboles de decisión en el bosque
- Tamaño de muestra: Controla el tamaño de la muestra utilizada para entrenar cada árbol

Después de entrenar los datos con cada modelo, se deseaba encontrar el mejor clasificador , para esto se evaluaron distintas métricas

- Precisión: Mide la proporción de instancias clasificadas correctamente como positivas en relación con todas las instancias clasificadas como positivas. Es decir, indica qué tan preciso es el modelo en la identificación de las instancias positivas.
- Recall: Mide la proporción de instancias positivas que se clasificaron correctamente en relación con todas las instancias reales positivas. Es decir, mide qué tan bien el modelo encuentra todas las instancias positivas.
- Accuracy: La exactitud es la métrica que mide la proporción de instancias clasificadas correctamente, ya sea positivas o negativas, en relación con todas las instancias. Es decir, indica qué tan preciso es el modelo en general.

- F1-score: Es una medida que combina la precisión y el recall en una sola métrica. Es útil cuando hay un desequilibrio entre las clases en los datos.

Para las métricas se utilizó el “Weighted Average” ya que este calcula la media resultante de cada métrica del modelo en el que se asigna un peso o importancia diferente a cada valor que se está promediando (dependiendo de la proporción de muestras en cada clase)

Para el primer caso (clasificación de potencial P300 vs no potencial P300) se utilizaron dos bases de datos (P300 Antonio y P300 Mayra). Los resultados nos arrojaron lo siguiente:

Métricas P300 Antonio

Clasificador	Accuracy	Precisión	Recall	F1-score
SVM Classifier	0.90	0.90	0.90	0.89
KNN Classifier	0.83	0.81	0.83	0.80
MLP	0.85	0.85	0.85	0.85
Decision Tree	0.77	0.77	0.77	0.77
Random Forest	0.86	0.88	0.84	0.84

Métricas P300 Mayra

Clasificador	Accuracy	Precisión	Recall	F1-score
SVM Classifier	0.79	0.84	0.79	0.75
KNN Classifier	0.73	0.71	0.73	0.64
MLP	0.83	0.83	0.83	0.83
Decision Tree	0.70	0.68	0.70	0.68
Random Forest	0.76	0.82	0.76	0.69

Como se observa, ambas bases de datos lograron resultados buenos, es decir, la manera de obtener datos fue la correcta. El clasificador que obtuvo mejores resultados con el primer sujeto de prueba (Antonio) fue el SVM Classifier con una exactitud, precisión y recall de 0.90, para este caso MLP y Random Forest también arrojaron buenas métricas. Para el sujeto de prueba 2 (Mayra) existen dos clasificadores con muy buenas métricas: MLP con una

exactitud de 0.83 y SVM Classifier con una exactitud de 0.79. En conclusión para la prueba P300 los mejores clasificadores fueron SVM Classifier y MLP

Para el segundo caso (clasificación de no tarea cognitiva (cruz) vs tarea cognitiva) se utilizaron tres bases de datos (cognitiva_Antonio, cognitiva_Raúl, cognitiva_Mayra) y los datos que nos arrojaron fueron los siguientes:

Métricas Cognitivas vs No Cognitiva Antonio

Clasificador	Accuracy	Precisión	Recall	F1-score
SVM Classifier	0.79	0.78	0.79	0.77
KNN Classifier	0.77	0.79	0.77	0.74
MLP	0.70	0.71	0.70	0.70
Decision Tree	0.79	0.79	0.79	0.79
Random Forest	0.84	0.84	0.84	0.83

Métricas Métricas Cognitivas vs No Cognitiva Mayra

Clasificador	Accuracy	Precisión	Recall	F1-score
SVM Classifier	0.69	0.69	0.69	0.67
KNN Classifier	0.73	0.73	0.73	0.73
MLP	0.68	0.67	0.68	0.65
Decision Tree	0.64	0.64	0.64	0.64
Random Forest	0.75	0.74	0.75	0.74

Métricas Métricas Cognitivas vs No Cognitiva Raúl

Clasificador	Accuracy	Precisión	Recall	F1-score
SVM Classifier	0.62	0.76	0.62	0.47
KNN Classifier	0.71	0.73	0.71	0.71
MLP	0.70	0.71	0.70	0.68
Decision Tree	0.65	0.67	0.65	0.66

Random Forest	0.80	0.80	0.80	0.80
----------------------	------	------	------	------

En estas pruebas, se puede observar que los datos arrojaron buenas métricas, por lo que tanto la interfaz como la manera de recolección de datos fueron buenos, es decir, si se puede hacer una clasificación cuando un sujeto está o no realizando una prueba cognitiva. Para este caso, para los tres sujetos el mejor clasificador con la mayor exactitud fue Random Forest.

Para el tercer caso (clasificación de tarea de cálculo (9-12) vs tarea de lectura (5-8) vs tarea de nombres de cosas (1-4)) se utilizaron tres bases de datos (clasificatareas_Antonio, clasificatareas_Raúl, clasificatareas_Mayra) y los datos que nos arrojaron fueron los siguientes

Métricas Clasificación de Tareas Antonio

Clasificador	Accuracy	Precisión	Recall	F1-score
SVM Classifier	0.43	0.49	0.43	0.37
KNN Classifier	0.41	0.44	0.41	0.40
MLP	0.41	0.38	0.41	0.34
Decision Tree	0.39	0.40	0.39	0.39
Random Forest	0.50	0.53	0.50	0.44

Métricas Clasificación de Tareas Mayra

Clasificador	Accuracy	Precisión	Recall	F1-score
SVM Classifier	0.56	0.77	0.56	0.46
KNN Classifier	0.58	0.50	0.58	0.51
MLP	0.39	0.15	0.39	0.22
Decision Tree	0.55	0.58	0.55	0.56
Random Forest	0.60	0.63	0.60	0.57

Métricas Clasificación de Tareas Raúl

Clasificador	Accuracy	Precisión	Recall	F1-score
SVM Classifier	0.38	0.76	0.38	0.21
KNN Classifier	0.69	0.73	0.69	0.66
MLP	0.45	0.39	0.45	0.36
Decision Tree	0.51	0.51	0.51	0.51
Random Forest	0.65	0.65	0.65	0.62

Finalmente, para la última prueba se observa que las métricas no son buenas, por lo tanto se puede concluir que la interfaz y la manera de recolección de datos no es correcta para la clasificación de tareas. Los datos del sujeto de prueba 3 fueron los que arrojaron mejores métricas. Los mejores clasificadores para este caso fueron Random Forest y KNN Classifier

Obtención de hiperparámetros óptimos

Como se mencionó anteriormente cada clasificador cuenta con hiperparámetros que hace el modelo óptimo, es por ello que es importante conocerlos. Para este trabajo se calcularon estos para SVM Classifier y KNN. Para el primero se utilizó la función GridSearch (cuyo objetivo es optimizar el rendimiento del modelo al encontrar la combinación adecuada de hiperparámetros que se ajuste mejor a los datos de entrenamiento. con cada combinación). El código se muestra a continuación

```
# Ajuste de hiperparámetros óptimos para el modelo seleccionado (SVM)
grid_search = GridSearchCV(models['SVM'], hyperparameters['SVM'], cv=3)
grid_search.fit(xA, yA)

# Hiperparámetros óptimos encontrados
best_params = grid_search.best_params_
```

El resultado arrojó lo siguiente

```
Hiperparámetros óptimos para SVM:
{'C': 0.1, 'kernel': 'linear'}
```

Para encontrar el mejor hiperparámetro de KNN se hicieron distintas pruebas con un rango de k del 1 al 9. El código se muestra a continuación


```
for i in range(1, 9):  
    print(f"\nPara k {i} los resultados son: ")  
    knn_classifier(xA, yA, i)
```


Después de la corrida del código, el valor de k que tuvo un mejor resultado fue para k=6

Selección de características


La selección de características es una técnica utilizada para reducir la dimensionalidad de un conjunto de datos al elegir un subconjunto relevante de características. Consiste en identificar las características más informativas y relevantes para la tarea de clasificación. En este estudio, se aplicó un enfoque de filtro para evaluar el rendimiento del clasificador SVM en diferentes pruebas con diferentes sujetos, el enfoque de filtro se basa en evaluar cada característica de forma independiente utilizando medidas estadísticas o heurísticas para determinar su relevancia con respecto al objetivo de la tarea. Para esto, se exploraron distintos valores de "k", que representa el número de características a las que se reduciría la matriz de datos. A continuación se muestra la representación de los resultados


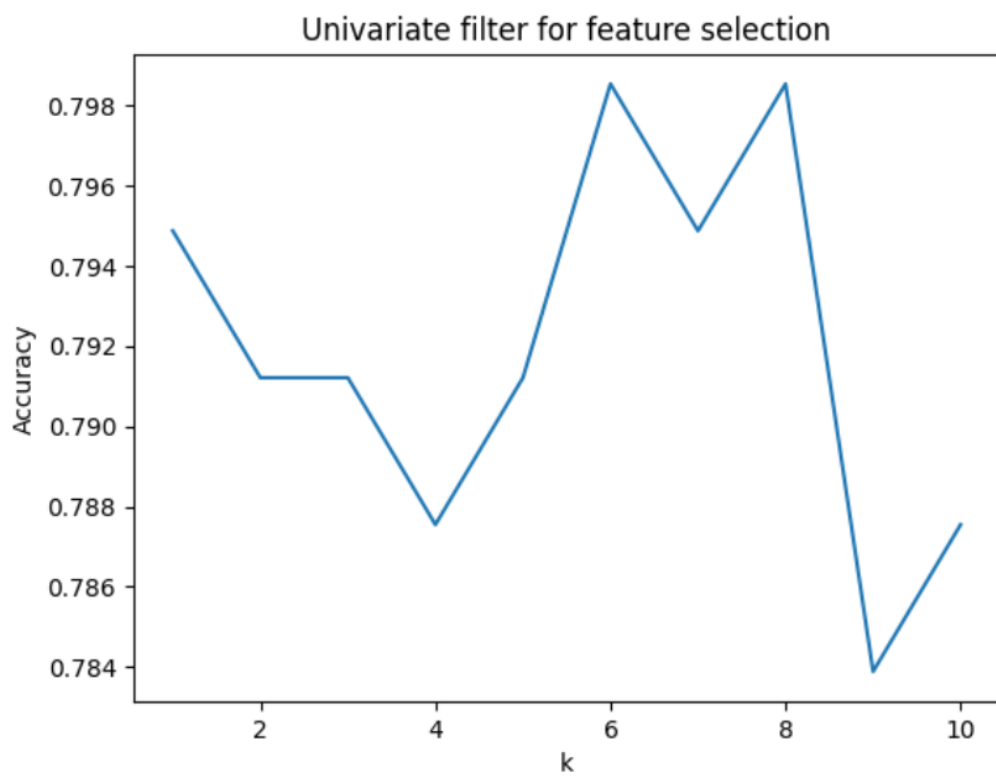
Gráfica P300 Antonio



Gráfica P300 Mayra

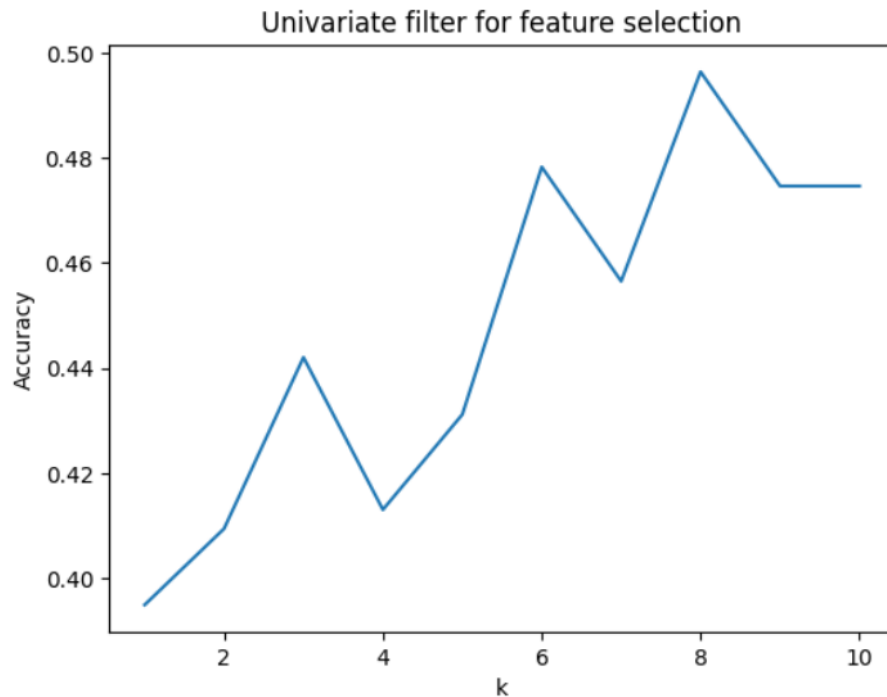
Al analizar las gráficas podemos asegurar que para la prueba P300 de los dos sujetos de prueba los mejores valores de k son 7 y 9 ya que tienen la mayor exactitud

Gráfica Cognitiva vs No Cognitiva Antonio


Gráfica Cognitiva vs No Cognitiva Mayra**Gráfica Cognitiva vs No Cognitiva Raúl**

Al analizar las gráficas podemos ver que en este caso para cada sujeto de prueba el mejor valor de k varía. Para el sujeto 1 el mejor valor de $k=9$, para el sujeto 2 el mejor valor de $k=6$ y para el sujeto 3 hay dos valores que arrojan la misma exactitud $k=6$ o $k=8$


Gráfica Clasificación de Tareas Antonio



Gráfica Clasificación de Tareas Mayra



Gráfica Clasificación de Tareas Raúl



Finalmente, para el caso 3 se puede observar una un patrón en las gráficas, los valores para k no difieren tanto, se encuentran entre $k=8$ y $k=10$.

Aprendizaje por transferencia

Para la última etapa del proyecto se entrenó un modelo de P300 con uno de los archivos de datos de uno de los sujetos, y se probó el mismo modelo con otro de los archivos de datos de otra persona para los clasificadores SVM, KNN y Random Forest. Para medir la efectividad del modelo se calcularon las métricas mencionadas anteriormente

Clasificador	Accuracy	Precisión	Recall	F-1 Score
SVM	0.75	0.65	0.75	0.69
KNN	0.77	0.66	0.77	0.70
Random Forest	0.77	0.65	0.77	0.70

Con estas métricas podemos observar que las medidas de accuracy bajan comparadas con las originales por lo que se puede inferir que los datos de ambos sujetos están dispersos o que sus bases no están completamente balanceadas.

Descripción del clasificador Random Forest

El clasificador Random Forest no fue visto en clase, por lo que a continuación se muestra la teoría del funcionamiento del mismo. Random Forest es un algoritmo de aprendizaje automático supervisado que se basa en la idea de que la combinación de múltiples modelos débiles puede generar un modelo más fuerte y preciso. Estos modelos débiles son árboles de decisión individuales que funcionan como "votantes" en el proceso de toma de decisiones del algoritmo. Cada árbol se entrena con una muestra aleatoria de datos de entrenamiento, conocida como "muestreo bootstrap", y produce una predicción.

El proceso de construcción del Random Forest comienza con el muestreo aleatorio. Se toma una muestra aleatoria de los datos de entrenamiento con reemplazo, lo que significa que una misma instancia puede aparecer varias veces o no aparecer en absoluto en la muestra. Esto crea conjuntos de datos de entrenamiento diferentes para cada árbol del bosque, lo que introduce variabilidad y diversidad en los árboles.

Una vez que se tiene el conjunto de datos de entrenamiento para un árbol específico, se construye un árbol de decisión utilizando un proceso de partición recursivo. En cada nodo del árbol, se selecciona un subconjunto aleatorio de atributos para considerar en lugar de utilizar todos los atributos disponibles. Esta selección aleatoria de atributos evita que los atributos más dominantes o correlacionados dominen la construcción del árbol, lo que mejora la diversidad en el bosque.

En la construcción del árbol, se utilizan diversos criterios de división, como la ganancia de información y la entropía, para determinar la mejor forma de dividir los datos y reducir la impureza en cada división. Este proceso continúa recursivamente hasta alcanzar un criterio de parada, como alcanzar una profundidad máxima o un número mínimo de instancias en cada hoja del árbol.

Una vez que se han construido todos los árboles del bosque, el Random Forest se utiliza para realizar predicciones en nuevos datos. En el caso de la clasificación, cada árbol emite una predicción y la clase final se determina por votación mayoritaria. Una de las ventajas clave del Random Forest es su capacidad para manejar conjuntos de datos grandes y complejos. El uso de múltiples árboles reduce el riesgo de sobreajuste y mejora la generalización del modelo, lo que lo hace menos sensible a datos ruidosos o atípicos. Además, el Random Forest

puede manejar atributos faltantes y manejar de manera efectiva conjuntos de datos desequilibrados.

Conclusión

Como conclusión de este proyecto, se puede asegurar que la encefalografía es una rama de estudio compleja pero importante para el desarrollo de nuevas tecnologías para la humanidad. Para el proyecto se hizo uso de 5 distintos métodos de clasificación, se investigaron sus características, función e hiperparámetros de cada uno y se pusieron a prueba en la investigación demostrando la importancia de la analítica de datos. Considero que el monitoreo de la actividad cerebral de una persona puede ser benéfico para su salud ya que el cerebro es un órgano fundamental en el funcionamiento del cuerpo humano y el monitoreo de su actividad puede proporcionar información valiosa para el diagnóstico y tratamiento de diversas condiciones médicas. Algunas aplicaciones específicas del monitoreo de la actividad cerebral podrían ser

- Diagnóstico de trastornos neurológicos como la epilepsia, el trastorno por déficit de atención e hiperactividad (TDAH) y la enfermedad de Alzheimer
- Rehabilitación neurológica: Puede utilizarse en terapias de rehabilitación para mejorar la función cerebral en personas que han sufrido lesiones cerebrales o accidentes cerebrovasculares.
- Mejoramiento cognitivo: Entrenamiento de la atención, la concentración y la memoria.

Con la encefalografía, existen otras variables o señales que se pueden monitorear con dispositivos médicos para desarrollar aplicaciones beneficiosas para la salud. Algunas de estas son:

1. Monitoreo de la frecuencia cardíaca
2. Monitoreo del sueño
3. Monitoreo de la actividad física
4. Nivel de estrés

Referencias

- Electroencefalografía.(s.f). *Mayo Clinic*. Recuperado de <https://www.mayoclinic.org/es-es/tests-procedures/eeg/about/pac-20393875>
- Interfaz cerebro-ordenador. (s.f.). *Unicorn*. Recuperado de <https://www.unicorn-bi.com/es/>
- Novo, C. (2010). Sistema Internacional 10-20. *Research Gate*. Recuperado de https://www.researchgate.net/figure/Figura-3-Sistema-Internacional-10-20-para-la-colocacion-de-los-electrodos_fig2_282294960
- What is Random Forest? (s.f.). *IBM*. Recuperado de <https://www.ibm.com/topics/random-forest>
- Yiu, T. (2019). Understanding Random Forest. *Towards Data Science*. Recuperado de <https://towardsdatascience.com/understanding-random-forest-58381e0602d2>